

LangChain RAG 评估报告

配套文件：rag_embedding_langchain_test.xlsx / rag_langchain_knowledge_word.docx

1. 评估目标

本报告用于验证 LangChain RAG 流程中检索结果是否能够稳定命中预期知识块，并给出基础的生成质量检查框架。

2. 测试集概览

当前测试集包含 8 条查询、10 条知识记录。每条查询都绑定一个 Expected Knowledge ID，并以 Hit@1 为默认通过标准。

ID	测试问题	预期知识	标准
T001	LangChain 里常用什么方法做递归文本切分？	K002	Hit@1
T002	FAISS 和 Chroma 在 RAG 中主要负责什么？	K004	Hit@1
T003	怎么减少召回结果内容过于相似？	K006	Hit@1
T004	RAG 的检索效果常用哪些指标评估？	K008	Hit@1
T005	为什么知识块要保存 source 和 version？	K009	Hit@1
T006	RAG 提示词怎样降低幻觉？	K007	Hit@1
T007	Embedding 在 RAG 中起什么作用？	K003	Hit@1
T008	top-k 太大可能有什么问题？	K010	Hit@1

3. 建议评估指标

检索层：Hit@K / Recall@K / MRR；生成层：答案相关性、忠实度、上下文相关性。对于小型测试集，可先以 Expected Knowledge ID 是否进入 Top-K 作为最直接的回归指标。

4. 执行建议

将 Excel 中的 Query 逐条送入 Retriever，记录预期知识块的 Actual Rank。Excel 的 Pass 列会依据 Expected Hit@K 自动判断。若检索通过但最终答案不稳定，再检查 Prompt、上下文拼接与模型生成参数。

5. 常见调优方向

优先检查 `chunk_size / chunk_overlap`、Embedding 模型、top-k、MMR、元数据过滤和重排序。每次只修改一个关键变量并重新跑同一批测试，便于确认改动是否真正提升检索效果。